

# الگوریتم تشخیص سرطان سینه با شبکه عصبی کانولوشنی

میلا د کلوندی

## چکیده

طبقه بندی خودکار سرطان سینه اغلب می تواند جان انسان ها را نجات دهد، زیرا تشخیص دستی معمولاً وقت گیر و گران است. از دهه گذشته، تکنیک های یادگیری عمیق به طور گسترده برای طبقه بندی خودکار سرطان از تصاویر MRI و CT استفاده شده است. در این تحقیق، مدل های یادگیری عمیق مبتنی بر هوش مصنوعی برای طبقه بندی تصاویر هشت نوع سرطان مانند سرطان ریه، مغز، سینه و دهانه رحم پیشنهاد شده اند را با استفاده از مدل مجموعه مبتنی بر یادگیری انتقال انجام داده است. برای تجزیه و تحلیل درستی و قابلیت اطمینان مدل پیشنهادی، ما از مجموعه داده "Multi Cancer Dataset" برای طبقه بندی استفاده کرده ایم. ما از تابع بهینه ساز آدام برای یافتن بهترین مقادیر هاپر پارامترها استفاده کرده ایم. انواع CNN از پیش آموزش دیده مانند VGGNet، DenseNet و MobileNet برای انتقال دانشی که با مجموعه داده ImageNet آموخته اند برای شناسایی انواع مختلف سلول های سرطانی استفاده می شود. خروجی تجمع به یک پرسپترون چند لایه برای تکمیل کار طبقه بندی نهایی وارد می شود. مدل های پیشنهادی مبتنی بر یادگیری انتقالی از دقت بیشتری نسبت به تکنیک های مدرن امروزی برخوردار هستند.

## کلید واژه ها

تشخیص سرطان، شبکه عصبی، شبکه عصبی کانولوشن، یادگیری انتقال

## 1- مقدمه

IDC ممکن است با گذشت زمان به دلیل متاستاز سلول ها به غدد لنفاوی و سایر قسمت های بدن تشدید شود. ناحیه سرطان خصومت بیماری را تعیین می کند. اگرچه تشخیص زودهنگام شانس بقا را تا 80% افزایش می دهد، این فرآیند بسیار پیچیده است و به آسیب شناسان آموزش دیده نیاز دارد [4]. یادگیری عمیق دستاوردهای قابل توجهی در غلبه بر مشکلات یادگیری ماشین سنتی به دست آورده است. این به طور موثر ویژگی ها و دانش مربوط به تصاویر خام را استخراج می کند و آن را به طور موثر برای طبقه بندی تصویر به کار می برد. شبکه عصبی کانولوشنل مبتنی بر یادگیری عمیق (CNN) در سال های اخیر محققین زیادی را در زمینه تصویربرداری پزشکی جذب کرده است. مشاهده می شود که موفقیت یادگیری عمیق تنها در صورتی امکان پذیر است که قدرت محاسباتی کافی، معماری پیچیده و حجم عظیمی از داده ها را داشته باشیم. با این حال، این سه ترکیب همیشه در دسترس نیستند زیرا این دستگاه ها قدرت

سرطان سینه شایع ترین نوع سرطان در بین زنان در سراسر جهان است. طبق یک گزارش فعلی، از هر 9 زن، یک نفر به سرطان سینه مبتلا است [1] و [2]. سرطان سینه از نظر ویژگی های مورفولوژیکی و بیولوژیکی متفاوت است و رفتارهای بالینی و نتایج درمانی مختلفی را نشان می دهد [3]. سرطان سینه به دلیل غلظت بیش از حد سلول ها در سینه رخ می دهد و در نتیجه توده هایی از ساختارهای تومور مانند در ناحیه سینه ایجاد می شود. این تومورها می توانند خوش خیم یا بدخیم باشند: توده خوش خیم غیرسرطانی است و در صورت عدم درمان ممکن است درمان نشود. ایجاد هر گونه درد یا تکثیر در بافت های مجاور. تومورهای بدخیم سرطانی هستند و ممکن است خطرناک باشند [1]. کارسینوم مجرای مهاجم (IDC) شایع ترین زیرگروه سرطان پستان است. تشخیص

سرطان استفاده شده است. در این بخش، تلاش‌های اخیر برای شناسایی/ طبقه‌بندی انواع سرطان با استفاده از مدل‌های یادگیری عمیق را خلاصه می‌کنیم.

شبکه‌های یادگیری عمیق مانند VGG-16 و ResNet-50 توسط Rezayi [7] برای تشخیص لوسمی لنفوبلاستیک حاد مورد استفاده قرار گرفتند. علاوه بر این، نویسندگان یک CNN با 10 لایه کانولوشن و شش الگوریتم یادگیری ماشینی رایج برای تقسیم سرطان خون به دو گروه تقسیم کردند. نویسندگان مدل‌های مختلف ML و CNN را در تشخیص این شرایط مقایسه کردند و به این نتیجه رسیدند که CNN از مدل‌های ML بهتر عمل می‌کند. Gunasekara [8] یک معماری یادگیری عمیق سه‌گانه با طبقه‌بندی‌کننده‌های پیاده‌سازی شده با CNN عمیق در سطح اول، و در سطح دوم، یک CNN مبتنی بر منطقه (RCNN) برای مکان‌یابی مناطق مورد نظر تومور پیشنهاد کرد. الگوریتم تقسیم بندی ChanVese برای مشخص کردن مرزهای غلیظ تومور برای تقسیم بندی در مرحله نهایی استفاده می‌شود. میانگین دقت برای این مدل 0.92 است.

برای درک بیشتر چگونگی بافت، ریخت شناسی و خواص نمودار بر دقت طبقه بندی تاثیر می‌گذارد، Reshma [9] مجموعه‌ای از مطالعات را انجام دادند که یک الگوریتم ژنتیک بهبود یافته و یک روش انتخاب ویژگی وزنی در ارتباط با CNN برای تشخیص سرطان سینه پیشنهاد داده‌اند. تعداد کمی از تصاویر با استفاده از یک تابع وضوح حاشیه نویسی می‌شوند و یک مکانیسم انتخاب برای متعادل کردن داده‌های آموزشی برای الگوریتم استفاده می‌شود. روش پیشنهادی در این تحقیق [10] دارای میزان دقت 91.94 درصد با تعداد کمی از داده‌های برجسب‌دار است.

Alanazi [14] ایده استفاده از CNN را برای بهبود دقت تشخیص خودکار سرطان سینه مطرح کرد. تجزیه و تحلیل مناطق بافت کارسینوم مجرای متخاصم در تصاویر کل اسلاید انجام شد. علاوه بر این، نویسندگان مدل‌هایی را بررسی کردند که از انواع معماری CNN برای تشخیص خودکار سرطان سینه استفاده می‌کنند. آنها یافته‌های این مدل‌ها را با آنهایی که توسط تکنیک‌های یادگیری ماشین تولید می‌شوند مقایسه کردند.

### 3- روش‌ها

این بخش زیربخش‌های مختلفی را نشان می‌دهد که تکنیک‌ها، مدل‌ها و گردش کار پیشنهادی را به تفصیل شرح می‌دهد.

#### 3-1- مدل‌های سبک وزن CNN

سی‌ان‌ان بهترین مدل‌ها برای تشخیص جزئیات تصویر و نشان دادن نتایج برجسته در بخش‌بندی، طبقه‌بندی، تشخیص و کارهای تشخیص تصویر هستند. CNN یک شبکه فید فوروارد است که دارای لایه‌های متعدد و سلسله مراتبی است [30]. معماری اصلی CNN شامل لایه‌های متناوب کانولوشن و ادغام است که به دنبال

محاسباتی و حافظه کمی دارند. بنابراین برای غلبه بر این وابستگی-ها، مدل‌های یادگیری عمیق کارآمد مورد نیاز است [6]. CNN سنتی به مجموعه داده‌های بزرگی نیاز دارد و با استفاده از مجموعه داده‌های کوچک نمی‌تواند به نتایج خوبی دست یابد. یادگیری انتقال را می‌توان با استخراج ویژگی‌ها از مجموعه داده‌های تصویر عمومی با استفاده از CNN عمیق از پیش آموزش دیده و اعمال مستقیم آنها در مجموعه داده‌های خاص و کوچک اعمال کرد که منجر به عملکرد بهتر و کاهش هزینه محاسباتی می‌شود [7]. از سال 2012 تاکنون، تغییرات و اختراعات زیادی در مدل‌های CNN گزارش شده است. بهبود قابل توجهی در اثربخشی CNN بین سال‌های 2015-2019 مشاهده شد. معمولاً عملکرد CNN در عمق مدل دیده می‌شود. با این حال، چالش‌هایی که معماری عمیق با آن مواجه است، از بین رفتن گرادینان، هزینه محاسباتی بالا و نیاز به حافظه است، در نتیجه این معماری‌ها را برای استقرار در دستگاه‌های محدودیت منابع نامناسب می‌سازد. تغییرات متفاوتی در مدل‌های CNN در رابطه با موضوعات ذکر شده پیشنهاد شده است [8]. روند کلی طراحی معماری سبک وزن بدون به خطر انداختن عملکرد است [9]. با توجه به اندازه و عملکرد سیستم توسعه یافته، باید یک مدل مؤثر برای طبقه‌بندی عکس‌های IDC و غیر IDC ایجاد شود. اگر مدل توسعه یافته در دستگاه‌های با محدودیت منابع کار کند، به متخصصان این حوزه کمک زیادی خواهد کرد. یک راه حل ممکن شامل استفاده از CNN های سبک وزن برای طبقه بندی تصاویر IDC و غیر IDC است [10].

طبقه بندی مؤثر داده های نامتعادل مورد نیاز است زیرا عدم تعادل کلاس در سناریوی دنیای واقعی طبیعی است. بسیاری از کارها پیشرفت یادگیری عمیق و محبوبیت آن را نشان می‌دهد، اما تنها تعداد انگشت شماری از کارها در زمینه یادگیری عمیق با داده‌های نامتعادل وجود دارد. روش‌های مختلف یادگیری عمیق برای رفع عدم تعادل کلاس وجود دارد. این روش‌ها را می‌توان به طور کلی به عنوان روش‌های سطح داده، سطح الگوریتم و ترکیبی طبقه بندی کرد. این مقاله از یک تکنیک ترکیبی برای رسیدگی به کلاس‌های عدم تعادل مجموعه داده استفاده می‌کند [11]. ما تقویت داده‌ها را برای مجموعه داده‌های آموزشی و دسته‌بندی مجموعه داده‌های نامتعادل با استفاده از یک مدل مجموعه در کار پیشنهادی انجام داده‌ایم. همچنین ما مجموعه‌ای از مدل‌ها را با استفاده از معماری‌های CNN از پیش آموزش دیده برای شناسایی و تشخیص خودکار سرطان سینه از تصاویر CT/MRI که از منابع مختلفی مانند Kaggle و غیره به دست آمده‌اند، توسعه می‌دهیم.

### 2- کارهای مرتبط

چندین روش سنتی برای تشخیص و طبقه بندی تومورها ساده و پیچیده وجود دارند که به زمان و کار شبانه روزی بیشتری نیاز دارند. اخیراً از مدل‌های یادگیری عمیق برای انجام طبقه بندی

### 3-3- CNN کم عمق پیشنهاد شده

مدل کم عمق CNN ارائه شده در این کار متوالی است. ما یک مدل متوالی را انتخاب کرده ایم که به ما امکان می دهد مدل را لایه به لایه بسازیم. مدل CNN کم عمق پیشنهادی شامل ترکیبی از لایه های کانولوشن، نرمال سازی دسته ای، max-pooling و ReLu است. یک معماری ساده CNN معمولاً شامل لایه کانولوشن، max pooling، dropout، ReLu، و softmax است. اما در معماری پیشنهادی، از لایه نرمال سازی دسته ای نیز استفاده کرده ایم زیرا همگرایی را تسریع می کند و دقت را در کار طبقه بندی تصویر بهبود می بخشد [14].

مدل پیشنهادی دارای لایه های پیچیدگی سه لایه، لایه های نرمال سازی دسته ای سه لایه، لایه های maxpool سه لایه، لایه های ReLu سه لایه و یک لایه کاملاً متصل است. در این مدل، ویژگی ها از کانولوشن های  $3 \times 3$  با 32 اندازه فیلتر استخراج می شوند. سپس نرمال سازی دسته ای برای عادی سازی نقشه ویژگی های بدست آمده از لایه قبلی و کاهش شانس ناپدید شدن گرادیان استفاده می شود. لایه نرمال سازی دسته ای با ادغام حداکثر  $22 \times 22$  دنبال می شود تا ابعاد داده و پیچیدگی محاسباتی کاهش یابد. کانولوشن  $33 \times 33$  با 64 اندازه فیلتر برای استخراج ویژگی استفاده می شود. برای بهبود دقت و افزایش غیر خطی بودن مدل از ترکیب نرمال سازی دسته ای، حداکثر تجمیع و ReLu استفاده می شود. در نهایت، یک کانولوشن  $33 \times 33$  دیگر با 128 اندازه فیلتر و ترکیبی از نرمال سازی دسته ای، max-pooling و ReLu استفاده می شود. سپس از یک لایه کاملاً متصل با 4608 نورون برای ترکیب ویژگی های لایه جلویی استفاده می شود. معماری مدل پیشنهادی در شکل 4 آورده شده است همچنین جزئیات هر لایه در جدول 1 نشان داده شده است.

### 4- آزمایشات

#### 4-1- دیتاست مورد استفاده

اولین مجموعه داده مورد استفاده برای این مطالعه در ابتدا شامل 162 تصویر WSI بود که از دانشگاه پنسیلوانیا و موسسه سرطان نیوجرسی جمع آوری شده بود. مجموعه داده بزرگی از IDC با استخراج نمونه های تصویری متعدد از هر بیمار ایجاد می شود و پاتولوژیست های خبره نواحی سرطان را حاشیه نویسی می کنند. بخش داده های مشروح 277524 به نمونه هایی با ابعاد  $50 \times 50$  پیکسل، که 78786 به IDC مثبت و 198738 متعلق به دسته IDC منفی هستند.

ما همچنین از مجموعه داده [34] BreakHis استفاده کرده ایم که در مجموع از 7909 تصویر تشکیل شده است که از این تعداد 2480 تصویر خوش خیم و 5429 تصویر هیستوپاتولوژیک بدخیم از 82 بیمار برای آزمایش استحکام مدل پیشنهادی گرفته شده است.

آن لایه های کاملاً متصل در انتها وجود دارد. در اینجا هر لایه دارای مجموعه ای از هسته های کانولوشن است و چندین تبدیل انجام می دهد. در برخی موارد، لایه کاملاً متصل با لایه ادغام میانگین جهانی بازیابی می شود [9].

با افزایش استفاده گسترده دستگاه های تلفن همراه و استفاده از CNN برای کاربردهای مختلف صنعتی، استقرار این مدل های یادگیری عمیق مبتنی بر CNN در دستگاه های تلفن همراه ضروری است. این امکان وجود دارد، تنها زمانی که مدل از نظر پارامترها و کمیت محاسباتی سبک باشد. عملیات ضروری CNN شامل استخراج کانولوشن مناطق محلی در تصویر است. با این حال، این پیچیدگی استاندارد از دو عیب اصلی رنج می برد: اولاً، مکانیسم استخراج ویژگی محلی نمی تواند مستقیماً ویژگی های کلی تصویر بزرگ تر را استخراج کند. ثانیاً، با افزایش تعداد کانال های ویژگی، پارامترهای هسته کانولوشن نیز افزایش می یابد و در نتیجه یک محاسبه پیچیده ایجاد می شود. با توجه به این مشکلات، روش های پیچیدگی مختلفی مانند پیچش متسع، پیچیدگی تغییر شکل پذیر، انحراف گروهی و پیچیدگی قابل تفکیک از نظر عمق توسعه یافتند [10]. ما در این مطالعه از یک مدل MobileNetV2 از پیش آموزش دیده استفاده کرده ایم که از پیچیدگی های قابل تفکیک عمقی استفاده می کند.

### 2-3- یادگیری انتقال

یادگیری انتقالی دانش به دست آمده از یک منبع متفاوت اما مرتبط را به حوزه های هدف منتقل می کند و در نتیجه عملکرد یادگیرندگان هدف را افزایش می دهد.

تعریف: دامنه منبع  $D_s$  و وظیفه یادگیری  $T_s$ ، به طور مشابه دامنه هدف  $D_t$  و وظیفه یادگیری  $T_t$ ، هدف از انتقال یادگیری بهبود یادگیری تابع پیش بینی هدف  $f_t(\cdot)$  در  $D_t$  با استفاده از دانش در  $D_s$  و  $T_s$  است، که در آن  $D_t \neq D_s$  یا  $T_t \neq T_s$  در اینجا یک دامنه  $\{X, P(X)\}$  است. [دامنه  $D$  را متشکل از فضای ویژگی  $X$  و توزیع احتمال حاشیه ای  $P(X)$  نشان می دهد]. بنابراین، شرط  $D_s$   $D_t$  یا  $X_s \neq X_t$  یا  $P_s(X) \neq P_t(X)$  را بیان می کند. به عنوان مثال، ویژگی های اصطلاح بین یک دامنه منبع و مقصد متفاوت است (از زبان های مختلف استفاده می کند)، یا توزیع های حاشیه ای متفاوت است. به همین ترتیب، یک کار با  $T \neq T'$   $\{Y, P(Y|X)\}$  نشان داده می شود.

بنابراین،  $T_s \neq T_t$  می گوید که یا  $Y_s \neq Y_t$  یا  $P_s(Y|X_s) \neq P_t(Y|X_t)$  (به عنوان مثال، فضای برچسب بین دامنه ها متفاوت است، یا توزیع های احتمال شرطی متفاوت است. بنابراین، اگر دامنه های هدف و منبع آشنا باشند، یعنی  $D_t \neq D_s$  و وظایف یادگیری آنها مشابه باشد، یعنی  $T_t \neq T_s$ ، یادگیری در اینجا به یک مشکل یادگیری ماشین معمولی تبدیل می شود [32].

## 5- نتایج و بحث

در این بخش، مدل پیشنهادی با سایر آثار و مدل‌های اخیر مقایسه می‌شود و بر اساس معیارهای مختلف مقایسه می‌شود. این بخش نشان می‌دهد که می‌توانیم از مدل‌های سبک وزن به جای CNN سنگین و عمیق برای کارهای طبقه‌بندی بدون به خطر انداختن عملکرد استفاده کنیم. برای نشان دادن اثربخشی مطالعه داده شده، ما روش خود را در مورد پارامترهای زیر مقایسه خواهیم کرد:

(1) مقایسه عملکرد با آثار اخیر.

(2) مقایسه در مورد سایر پارامترها.

مقایسه عملکرد شامل دقت، دقت متعادل (BAC)، حساسیت، ویژگی، دقت، F1-measure و غیره. برای مثال، این پارامترها را می‌توان به صورت زیر محاسبه کرد:

$$1. \text{Precision} = TP / (TP + FP)$$

$$2. \text{Sensitivity} = TP / (TP + FN)$$

$$3. \text{Specificity} = TN / (TN + FP)$$


$$4. \text{F1 Score} = 2(\text{Precision} * \text{Recal}) / (\text{Precision} + \text{Recal})$$

$$5. \text{Accuracy} = (TP + TN) / (TP + FP + TN + FN)$$

$$6. \text{BalancedAccuracy(BAC)} = (\text{Sensitivity} + \text{Specificity}) / 2$$

	precision	recall	f1-score	support
0	1.00	1.00	1.00	244
1	1.00	0.98	0.99	254
2	0.98	1.00	0.99	255
3	1.00	1.00	1.00	247
accuracy			0.99	1000
macro avg	1.00	1.00	1.00	1000
weighted avg	1.00	0.99	0.99	1000

این معیارها عملکرد کار پیشنهادی را با دو مجموعه داده نامتعادل مختلف اندازه‌گیری می‌کنند. در اینجا TP مثبت واقعی، FP مثبت کاذب، TN منفی واقعی و FN منفی کاذب است. در نکته دوم، سایر پارامترها به اندازه مدل، تعداد پارامترهای قابل آموزش و کلی مدل و زمان پیش‌بینی مورد نیاز مدل پیشنهادی نسبت به مدل‌های دیگر اشاره دارد. این پارامترها برای بحث در این مطالعه ضروری هستند، زیرا اشاره کردیم که مدل پیشنهادی سبک وزن است که به حافظه کمتر و زمان کمتری برای اجرا نیاز دارد.



تصاویر استفاده شده در این مجموعه داده دارای فاکتورهای بزرگنمایی مختلفی مانند x400، x200، x100، x40، 3 کانال RGB، عمق 8 بیت در هر کانال، فرمت (700x460) پیکسل، 3 توزیع تصویر توپوگرافی سینه از نوع بدخیم و خوش خیم را که در سلول‌های توپوگرافی مختلف در زیر میکروسکوپ طبقه‌بندی شده‌اند را نشان می‌دهد. شکل 8 تکه‌های تصویری از فاکتورهای بزرگنمایی متفاوت از هر کلاس خوش خیم و بدخیم را نشان می‌دهد. ما این دو مجموعه داده را به دلیل عدم تعادل بسیار در نظر گرفته‌ایم، و مدل ما می‌تواند به خوبی با این مجموعه داده‌های نامتعادل تنها با کمی پیش‌پردازش داده عمل کند. علاوه بر این، مجموعه داده BACH نیز در این کار برای بررسی عملکرد مدل پیشنهادی در سناریوی چند کلاسه استفاده می‌شود. مجموعه داده BACH شامل 400 تصویر بافت شناسی رنگ آمیزی شده با E&H است که به چهار دسته تقسیم می‌شوند: سرطان خوش خیم، نرمال، درجا و سرطان مهاجم. هر کلاس شامل 100 تصویر است. از این رو مجموعه داده متعادل (نشان داده شده در جدول 4). تصویر ذخیره شده با فرمت فایل تصویری برجسته‌گذاری شده (tiff) با ضریب بزرگنمایی 200 برابر است. ما مجموعه داده را به صورت تصادفی به 75 و 25 درصد تقسیم کردیم [35]. در مجموع، از سه مجموعه داده در این کار استفاده شد، سه، دو مجموعه داده نامتعادل و از کلاس باینری (IDC و BreakHis)، در حالی که مجموعه داده سوم متعادل و چند کلاسه (BACH) است پردازش دیتا

## 2-4- پردازش دیتا

در این مطالعه از تقویت و نرمال سازی داده‌ها به عنوان راهبردهای پیش پردازش داده‌ها استفاده شده است. توضیح مختصری در مورد هر دو تکنیک در زیر ارائه شده است: افزایش داده‌ها: به طور کلی برای افزایش اندازه داده‌ها انجام می‌شود زیرا آموزش CNN مستعد بیش از حد برازش است و در نتیجه تشخیص کم می‌شود [36]. دلیل دیگر افزایش تنوع داده‌های آموزشی بدون جمع‌آوری داده‌های جدید است. مطالعه ما از تقویت برای افزایش اندازه داده‌های آموزشی و متنوع کردن داده‌های آموزشی ما به طور ضمنی استفاده کرد. در اینجا، تکنیک‌های مختلف افزایش داده‌ها مانند چرخش افقی، چرخش عمودی، چرخش و غیره برای مجموعه داده‌های آموزشی همانطور که در جدول 5 زیر بحث شده است، استفاده می‌شود: عادی‌سازی: عادی‌سازی شدت یکی دیگر از مراحل پیش پردازش ضروری برای به دست آوردن مقادیر در همان محدوده برای هر ورودی است. تصویر قبل از ارائه آن به یک مدل CNN نرمال سازی Min-Max برای عادی سازی تصاویر ورودی به یک توزیع نرمال استاندارد محدوده شدت استفاده می‌شود [01].

networks,” in Proc. IEEE 5th Inf. Technol. Mechatron. Eng. Conf., 2020, pp. 1713–1720.

- [11] J. M. Johnson and T. M. Khoshgoftaar, “Survey on deep learning with class imbalance,” J. Big Data, vol. 6, no. 1, 2019, Art. no. 6.
- [12] S. Al-Stouhi and C. K. Reddy, “Transfer learning for class imbalance problems with inadequate data,” Knowl. Inf. Syst., vol. 48, no. 1, pp. 201–228, 2016.
- [13] L. Ge, J. Gao, H. Ngo, K. Li, and A. Zhang, “On handling negative transfer and imbalanced distributions in multiple source transfer learning,” in Proc. SIAM Int. Conf. Data Mining, 2013, pp. 261–269.
- [14] F. Lei, X. Liu, Q. Dai, and B. W. K. Ling, “Shallow convolutional neural network for image classification,” SN Appl. Sci., vol. 2, no. 1, pp. 1–8, 2020.
- [15] M. Sandler, A. Howard, M. Zhu, A. Zhmoginov, and L. C. Chen, “MobileNetV2: Inverted residuals and linear bottlenecks,” in Proc. IEEE Comput. Soc. Conf. Comput. Vis. Pattern Recognit., 2018, pp. 4510–4520.
- [16] S. M. McKinney et al., “International evaluation of an AI system for breast cancer screening,” Nature, vol. 577, no. 7788, pp. 89–94, 2020.
- [17] D. Shen and G. Wu, and H.-I. Suk, “Deep learning in medical image analysis,” Adv. Exp. Med. Biol., vol. 1213, pp. 3–21, 2020.
- [18] A. Maier, C. Syben, T. Lasser, and C. Riess, “A gentle introduction to deep learning in medical image processing,” Z. Med. Phys., vol. 29, no. 2, pp. 86–101, 2019.
- [19] A. Rehman, S. Naz, M. I. Razzak, F. Akram, and M. Imran, “A deep learning-based framework for automatic brain tumors classification using transfer learning,” Circuits Syst. Signal Process., vol. 39, no. 2, pp. 757–775, 2020.
- [20] D. Varshni, K. Thakral, L. Agarwal, R. Nijhawan, and A. Mittal, “Pneumonia detection using CNN based feature extraction,” in Proc. IEEE 3rd Int. Conf. Electr. Comput. Commun. Technol., 2019, pp. 1–7.
- [21] R. Krithiga and P. Geetha, “Breast cancer detection, segmentation and classification on histopathology images analysis: A systematic review,” Arch. Comput. Methods Eng., vol. 28, pp. 2607–2619, 2021.
- [22] X. Shu, L. Zhang, Z. Wang, Q. Lv, and Z. Yi, “Deep neural networks with region-based pooling structures for mammographic image classification,” IEEE Trans. Med. Imag., vol. 39, no. 6, pp. 2246–2255, Jun. 2020.
- [23] S. Boumaraf, X. Liu, Z. Zheng, X. Ma, and C. Ferkous, “A new transfer learning based approach to magnification dependent and independent classification of breast cancer in histopathological images,” Biomed. Signal Process. Control, vol. 63, 2021, Art. no. 102192.
- [24] H. Yang, J. Y. Kim, H. Kim, and S. P. Adhikari, “Guided soft attention network for classification of breast

```
model.evaluate(x_valid, y_valid, batch_size=256)
```

```
16/16 [=====] - 3s 174ms/step - loss: 0.0134 - accuracy: 0.9955  
[0.013415408320724964, 0.9955000281333923]
```

## 6- نتیجه گیری و کار آینده

ما در این کار طبقه‌بندی باینری و چند طبقه‌ای را با استفاده از مجموعه داده‌های تصویر MRI/CT انجام داده‌ایم. مدل گروه سبک وزن مبتنی بر یادگیری انتقال برای استقرار مجموعه داده‌های تصویر MRI توسعه یافته است. نتایج با چندین چارچوب موجود مقایسه می‌شوند. مدل ما بالاترین دقت و ویژگی 99.5% را بدست آورد. مدل پیشنهادی سبک وزن است و ممکن است به طور موثر در دستگاه‌های تعبیه‌شده برای کاربردهای بلادرنگ مانند FPGA مستقر شود

## مراجع

- [1] M. Tariq, S. Iqbal, H. Ayesha, I. Abbas, K. T. Ahmad, and M. F. K. Niazi, “Medical image based breast cancer diagnosis: State of the art and future directions,” Expert Syst. Appl., vol. 167, 2021, Art. no. 114095
- [2] S. Bharati, P. Podder, and M. R. H. Mondal, “Artificial neural network based breast cancer screening: A comprehensive review,” Int. J. Comput. Inform. Syst. Ind. Manage. Applications, vol. 12 pp. 125–137, 2020
- [3] J. Y. S. Tsang and G. M. Tse, “Molecular classification of breast cancer,” Adv. Anat. Pathol., vol. 27, no. 1, pp. 27–35, 2020
- [4] A. Seemendra, R. Singh, and S. Singh, “Imbalanced breast cancer classification using transfer learning,” IEEE/ACM Trans. Comput. Biol. Bioinforma., vol. 694, no. 1, pp. 425–436, Jan./Feb. 2021.
- [5] Y. Celik, M. Talo, O. Yildirim, M. Karabatak, and U. R. Acharya Automated invasive ductal carcinoma detection based using deep transfer learning with whole-slide images,” Pattern Recognit. Lett., vol. 133, pp. 232–239, 2020
- [6] B. Wu, “Efficient deep neural networks,” Ph.D. thesis, Univ. California, Berkeley, CA, USA, 2019.
- [7] S. U. Khan, N. Islam, Z. Jan, I. Ud Din, and J. J. P. C. Rodrigues, “A novel deep learning based framework for the detection and classification of breast cancer using transfer learning,” Pattern Recognit. Lett., vol. 125, pp. 1–6, 2019
- [8] Z. Li, W. Yang, S. Peng, and F. Liu, “A survey of convolutional neural networks: Analysis, applications, and prospects,” 2020, *arXiv:2004.02806*
- [9] A. Khan, A. Sohail, U. Zahoora, and A. S. Qureshi, “A survey of the recent architectures of deep convolutional neural networks,” Artif. Intell. Rev., vol. 53, no. 8, pp. 5455–5516, 2020.
- [10] Y. Zhou, S. Chen, Y. Wang, and W. Huan, “Review of research on lightweight convolutional neural



- [37] A. Paszke et al., "Automatic differentiation in pytorch," paszke2017automatic, vol. 5, pp. 1–4, 2017.
- [38] M. S. Reza and J. Ma, "Imbalanced histopathological breast cancer image classification with convolutional neural network," in Proc. Int. Conf. Signal Process., 2019, pp. 619–624.
- [39] X. Li, X. Shen, Y. Zhou, X. Wang, and T. Q. Li, "Classification of breast cancer histopathological images using interleaved densenet with SENet (IDSNet)," PLoS One, vol. 15, no. 5, pp. 1–13, 2020.
- [40] W. Nawaz, S. Ahmed, A. Tahir, and H. Aqeel Khan, Classification of Breast Cancer Histology Images Using ALEXNET. Berlin, Germany: Springer, 2018.
- [41] S. Kwok, Multiclass Classification of Breast Cancer in Whole-Slide Images. Berlin, Germany: Springer, 2018.
- [42] S. H. Kassani, P. H. Kassani, M. J. Wesolowski, K. A. Schneider, and R. Deters, "Breast cancer diagnosis with transfer learning and global pooling," in Proc. 10th Int. Conf. Inf. Commun. Technol. Convergence, 2019, pp. 519–524.
- [25] S. Sharma and R. Mehra, "Conventional machine learning and deep learning approach for multi-classification of breast cancer histopathology images—A comparative insight," J. Digit. Imag., vol. 33, no. 3, pp. 632–654, 2020.
- [26] S. Acharya, A. Alsadoon, P. W. C. Prasad, S. Abdullah, and A. Deva, "Deep convolutional network for breast cancer classification: Enhanced loss function (ELF)," J. Supercomput., vol. 76, no. 11, pp. 8548–8565, 2020.
- [27] C. T. Sari and C. Gunduz-Demir, "Unsupervised feature extraction via deep learning for histopathological classification of colon tissue images," IEEE Trans. Med. Imag., vol. 38, no. 5, pp. 1139–1149, May 2019.
- [28] M. Saini and S. Susan, "Deep transfer with minority data augmentation for imbalanced breast cancer dataset," Appl. Soft Comput., vol. 97, 2020, Art. no. 106759.
- [29] E. Wu, K. Wu, and W. Lotter, "Synthesizing lesions using contextual GANs improves breast cancer classification on mammograms," in Proc. Mach. Learn. Res. Conf., 2020.
- [30] S. Garg and P. Singh, "State-of-the-art review of deep learning for medical image analysis," in Proc. 3rd Int. Conf. Intell. Sustain. Syst., 2020, pp. 421–427.
- [31] A. G. Howard et al., "MobileNets: Efficient convolutional neural networks for mobile vision applications," in Proc. IEEE Conf. Comput. Vis. Pattern Recognit., 2017.
- [32] S. J. Pan and Q. Yang, "A survey on transfer learning," IEEE Trans. Knowl. Data Eng., vol. 22, no. 10, pp. 1345–1359, Oct. 2010.
- [33] A. Cruz-Roa et al., "Automatic detection of invasive ductal carcinoma in whole slide images with convolutional neural networks," Med. Imag. Digit. Pathol., vol. 9041, no. 216, 2014, Art. no. 904103. [Online]. Available: <https://academictorrents.com/details/e40bd59ab08861329ce3c418be191651f35e2ffa>
- [34] F. A. Spanhol, L. S. Oliveira, C. Petitjean, and L. Heutte, "A dataset for breast cancer histopathological image classification," IEEE Trans. Biomed. Eng., vol. 63, no. 7, pp. 1455–1462, Jul. 2016. [Online]. Available: <https://web.inf.ufpr.br/vri/databases/breast-cancerhistopathological-database-breakhis/>
- [35] G. Aresta et al., "BACH: Grand challenge on breast cancer histology images," Med. Image Anal., vol. 56, pp. 122–139, 2019.
- [36] S. H. Kassani, P. H. Kassani, M. J. Wesolowski, K. A. Schneider, and R. Deters, "Classification of histopathological biopsy images using ensemble of deep learning networks," in Proc. Conf. Cent. Adv. Stud. Collab. Res., Proc. 29th Annu. Int. Conf. Comput. Sci. Softw. Eng., 2020, pp. 92–99.